


GSM8K 上的思维链消融 (n=200 题 × 3 条件, 模型 global:deepseek-v4.1-flash)



判分伪影: 6 次数值相等但字符串不同 (如 12 vs 12.00), 另 2 次解析失败。

结论: 对推理模型而言, 提示方式几乎不改变结果; 主要误差来自题目难度与判分规则, 而不是提示。

数据: GSM8K 测试集 (Cobbe et al., 2021), aidoc/experiment-cot-gsm8k.json, temperature 0, 串行调用