

有证据与无证据时，写作门禁如何改变结构化输出：一次 32 次生成试点

SciencePrism 内部工程报告

2026 年 9 月

摘要

背景：本研究关注检索增强生成中的主张溯源问题：如何让写作阶段生成的每条主张都指向可核验来源。现有写作门禁由两个代码机制组成：`validateStageEvidence` 会把 Paper Claim 的 Evidence id 解析到项目 Ledger，通常拒绝缺失或未核验的证据，但允许已在 `unsupportedClaims` 中显式披露的写作 claim 继续流转；`runResearchHarnessStage` 在解析或 Evidence 校验失败时，对已成功传输的响应重试一次，并把校验错误与不得虚构 id 的指令传给修复尝试。

方法：本文报告一次小规模工程试点，在同一研究问题、同一模型 (`global:deepseek-v4.1-flash`) 上比较四臂各 8 次生成：A 为 no-gate (移除提示规则、事后测量)，B 为 prompt-only (有规则但不拦截)，C 为 enforced (有规则、校验、最多一次修复)，D 为 enforced-no-evidence (不给 Evidence 上下文)。观测指标包括有效 JSON、被接受比例、claim-evidence 覆盖率、未知引用 id 数与模型自报 `unsupportedClaims` 数。

结果：A/B/C 三臂有效 JSON 与接受率均为 8/8，覆盖率 1.00，未知 id 为 0；模型自报 `unsupportedClaims` 平均为 0.38/2.50/2.25，B-A=+2.12 (约 6.6 倍)，C-B=-0.25。D 臂有效 JSON 5/8、接受 1/8，6 个引用全部不在 Ledger 中；唯一被接受的 rep5 引用了不存在的“none”，但因该 claim 被显式登记为 `unsupported` 而按披露路径放行。上述数字均来自尚未独立核验的实验记录，且自报字段没有人工真值；覆盖率只度量 ID 是否出现，可以在所有 ID 均无效时仍为 1.00。

结论：本文结论只限于本次工具行为。门禁的设计目标是披露与拦截并行，而不是零容忍伪引用拦截；本次试点不能用于声称真实 `unsupported assertions` 减少，也不能用于声称门禁可阻止伪造引用。全部实验数字仍待独立核验。

1 动机与问题

研究问题是如何让检索增强生成把每条生成的主张追溯到可核验来源。本项目已有的写作门禁由两个代码机制组成。

其一，`validateStageEvidence` (位于 `apps/backend/src/services/evidenceLedger/index.js`) 会把 Paper Claim 的 Evidence id 解析到项目 Ledger，通常拒绝缺失或未核验的证据，但允许已在 `unsupportedClaims` 中显式披露的写作 claim 继续流转。其二，`runResearchHarnessStage` (位于 `apps/backend/src/services/researchResearch/harnessAdapter.js`) 在解析或 Evidence 校验失败时，对已成功传输的响应重试一次，并把校验错误与不得虚构 id 的指令传给修复尝试。

本试点要问的是：把这两类机制组合进写作阶段后，结构化输出的有效性与引用行为会怎样改变，以及在无 Evidence 上下文时会发生什么。需要预先说明，本文的全部实验数字转述自尚未独立核验的实验记录 `evidence-19e177ec-9a6c-4bac-b897-03c7a6f61b50`，该记录状态为 `pending`。

臂	生成	有效 JSON	接受	平均 claims	覆盖率	引用/次	伪造 id	自报 unsup.	平均秒
A (no-gate)	8	8/8	8/8	3.63	1.00	7.25	0	0.38	25.76
B (prompt-only)	8	8/8	8/8	3.63	1.00	7.50	0	2.50	19.14
C (enforced)	8	8/8	8/8	3.75	1.00	7.00	0	2.25	18.15
D (enforced-no-evidence)	8	5/8	1/8	0.75	1.00	0.75	6	1.13	49.05

表 1: 四臂原始汇总指标。D 臂另有 7 次修复, 总 attempts 为 39。覆盖率列仅度量 ID 是否出现, 不度量 ID 是否有效; “自报 unsup.” 列为模型自报未支持项均值, 不是人工真值。数据尚未独立核

2 方法

2.1 实验设计

本试点为四臂消融, 每臂 8 次生成, 同一研究问题, 模型固定为 `global:deepseek-v4.1-flash`。

- A 为 no-gate: 移除提示中的证据规则, 只在事后测量;
- B 为 prompt-only: 提示中包含规则但不做拦截;
- C 为 enforced: 提示含规则、进行校验, 并最多触发一次修复;
- D 为 enforced-no-evidence: 保留 enforced 机制但不向模型提供 Evidence 上下文。

共 32 次初始生成, D 臂另发生 7 次修复, 总 attempts 为 39。

2.2 观测指标

观测指标为: 有效 JSON 次数、被接受次数、claim-evidence 覆盖率、未知引用 id 数、模型自报 `unsupportedClaims` 数。需要强调, 本试点没有独立重复与随机种子设计, 分析单位是单次生成, 比较只描述本次工具运行。`unsupportedClaims` 是模型自报字段, 不是人工标注的真值; 覆盖率只检查 ID 是否出现, 不检查 ID 是否有效。

3 结果

以下数字转述自 `aidoc/experiment-evidence-gate.json`, 该实验记录尚未独立核验。

A/B/C 三臂的有效 JSON 均为 8/8, 接受率均为 8/8, 覆盖率均为 1.00, 未知 id 均为 0。模型自报 `unsupportedClaims` 平均每次为 0.38 (A)、2.50 (B)、2.25 (C); B 相对 A 上升 +2.12 (约 6.6 倍), C 相对 B 下降 -0.25。这些自报字段反映模型在文本中声明的未支持主张数量, 不是人工核验后的真值, 不能解读为真实 `unsupported assertions` 的减少或增加。

D 臂有效 JSON 为 5/8, 接受率为 1/8, 6 个引用全部在 Ledger 中不存在。唯一被接受的 D 输出 rep5 引用了不存在的 “none”, 但由于对应 claim 被显式登记为 `unsupported`, 代码按披露路径允许其继续流转; 这不应被描述为“引用通过验证”或“已验证引用”。D 臂 7 次重试后没有任何失败结果转为接受, rep5 是首轮通过。

D 臂覆盖率 1.00 只表示输出里出现了 ID, 不代表 ID 有效; 覆盖率与接受率是不同量纲的指标, 不能相互替代。换言之, 即使所有 ID 都无效, 覆盖率仍可为 1.00。

结构化写作中的证据门禁

C/D 的代码门禁路径：输入证据 → 生成主张 → 校验 → 接受或修复；A/B 为对照




图 1: 证据门禁的结构化写作路径及四臂干预。主流程表示 C/D 的代码校验与最多一次修复；A/B 仅作为无代码拦截的对照。显式披露的未支持主张可按例外路径放行，因此「接受」不代表引用 ID 有效。底部接受次数来自尚未独立核验的试点记录。

4 解释与讨论

两个代码机制解释了观察到的行为。

其一，校验器对缺失或未核验证据通常拒绝，但对显式披露的不支持 claim 放行，因此门禁不是零容忍的伪引用拦截。D 臂 rep5 的放行正是这一披露路径的体现，而不是对不存在 id 的通过。该输出引用的“none”并不在 Ledger 中，不能被视为有效引用。

其二，修复重试只对已成功传输的响应生效，它携带校验错误与不得虚构 id 的指令，但无法给模型提供可引用的证据，因此对无证据可引用的 D 臂没有产生任何把失败转为接受的效果。D 臂 7 次重试后没有失败结果转为接受，rep5 是首轮通过。

A/B/C 三臂的高覆盖率与零未知 id 说明在证据上下文存在时，本次运行没有观察到引用成本；但这不等于真实世界的引用正确性，因为这里的覆盖率只检查 ID 是否出现，接受也只检查门禁是否放行。模型自报 unsupportedClaims 在 B、C 两臂高于 A 臂，这一差异来自自报字段，不能解读为真实未支持主张的增加或减少。

5 局限

- 每臂仅 8 次生成，样本量很小，无法支撑统计推断。
- 只覆盖一个研究问题，无法评估跨问题稳定性。
- 只使用一个模型 global:deepseek-v4.1-flash，不能推广到其他模型。

- 原始回复未留存，无法进行二次判读、错误归类或独立复评。
- `unsupportedClaims` 为模型自报字段，没有人工真值，不能作为真实未支持主张率。
- A-C 上下文中的 3 个已确认 paper id 与研究问题相关性有限，可能影响引用行为。
- 结果仅反映本次工具行为，不能推广到其他任务、门禁实现或真实 RAG 系统。
- 不能据此声称真实 `unsupported assertions` 减少，也不能声称门禁可阻止伪造引用。
- 实验记录 `evidence-19e177ec-9a6c-4bac-b897-03c7a6f61b50` 仍为 `pending`，本文中引用它的每条 `claim` 都只是转述未核验记录。
- 未报告随机种子、置信区间或显著性检验，且这些设计事实在本次试点中并未提供。

6 结论

在本次 32 次初始生成、D 臂 7 次修复的试点中，证据门禁在证据上下文存在时保持了 8/8 的有效 JSON、8/8 的接受率与 1.00 的覆盖率，并伴随模型自报未支持主张的增加；在无 Evidence 上下文时，接受率降至 1/8，全部引用均不在 Ledger 中，且唯一被接受项是经显式披露后放行的。该门禁的设计目标是披露与拦截并行，而不是零容忍伪引用拦截；上述全部实验数字仍待独立核验。

7 可复现性与数据/代码可用性

7.1 运行命令与数据文件

运行命令为：

`nodescripts/experiment-evidence-gate.mjs8`

数据文件为：`aidoc/experiment-evidence-gate.json`。

本次成稿没有重跑 32 次模型实验；表格和图根据现存 JSON 数据及逐次记录整理，原始模型回复没有留档，实验 Evidence 状态仍为 `pending`，因此未进行独立复评。

7.2 内部来源

本文涉及的主要内部来源如下：

- 实验脚本：`scripts/experiment-evidence-gate.mjs`
- 实验数据：`aidoc/experiment-evidence-gate.json`
- 证据校验机制：`evidenceLedger/index.js`
- 实验记录：Evidence Ledger 中的四臂记录（`pending`）
- 代码机制证据 id：`code-writing-evidence-validator`、`code-writing-repair-retry`

本报告不引用外部文献，也不对在内部来源中出现的机制或结果作额外断言。数据与代码可用性以本次内部工程记录为限；在独立核验完成前，表 1 与图 1 中的数值仅应视为试点转述。